项目创新说明

面向连续任务的低开销多智能体协作系统
版本：第8.0版 | 更新：2026年10月1日 | 主要创新：2项

项目采用同一基础模型承担规划、检索、推理和最终回答四种角色，支持连续问答与代码执行。三种协作方式独立运行。知识库提前准备；任务期间写回原始关系证据。当前隐状态路线接续完整缓存，不额外执行末层反馈迭代；新证据仍首次经过完整模型。

创新一 角色依赖驱动的计算状态生命周期管理

最接近的已有工作 LatentMAS [1] 的跨角色工作记忆传递，以及按词元重要性淘汰缓存的 H□O [2]。

已有方案具备的能力 LatentMAS 已实现末层连续表示推理、各层键值缓存接续和仅最终角色生成文字。H□O 已能依据注意力贡献与近期性保留部分缓存。这些基础能力不单列为本项目新增贡献。

本项目新增贡献 把缓存片段与“内容类型、所属轮次、最后需要它的角色”关联，按工作流声明的期限回收。来源证据与问题不参与重要性裁剪；角色提示供下游使用后释放；旧回答保留到下一题完成。针对混合结构，只回收完整注意力层的到期位置，递归状态保持原张量。物理存储长度与原始位置编码分别维护。

状态内容	保留与回收规则
公共规则、问题、来源证据、外部结果	会话内保留
角色提示	下一个角色完成后释放；最终角色提示在本题结束释放
内部消息边界	本题回答完成后释放
历史回答的注意力条目	保留当前轮与上一轮；更早轮次到期释放
线性注意力的递归状态	保持原张量，不按词元位置裁剪

代码位置与验证

competition_agents/latent_hidden/state_lifecycle.py:22
片段分类、消费者期限及跨题回答期限；第37行执行布局检查与回收。

competition_agents/llm/latent_only_chat.py:112
带原始位置编码接续各层缓存；角色成功完成后执行回收。

tests/test_state_lifecycle.py:23
核验保留键值逐项一致、递归状态原值与地址不变、未知布局不发生部分变更。

固定来源、同一最终提示的十题机制消融见第4页。该贡献属于工作流感知的状态管理机制；回收改变后续注意力可访问的条目，不等于证明历史语义完全无损，也不把缓存容量计作网络通信量。

创新二 超图证据与计算状态的一致性复用

最接近的已有工作 HyperGraphRAG [3] 的多元关系组织与检索，以及 LatentMAS [1] 的驻留工作记忆接续。

已有方案具备的能力 HyperGraphRAG 已将多实体关系组织成超边，使用实体与超边检索，并结合原文片段生成答案；也支持图的增量更新。LatentMAS 已避免重新编码前一角色的完整工作记忆。超图、多跳、缓存复用本身不单列为新增贡献。

本项目新增贡献 让事实的来源身份同时贯穿建图、证据存储、协议交接和隐状态去重。每条证据保留主体、关系、客体、否定及限定；代词、简称和同名作品在来源作用域内绑定，避免仅凭名称相同合并。协议的来源标题独立成表，已召回关系完整交接；隐状态按事实标识与内容哈希判断是否已编码，相同来源版本直接复用，改变后的事实重新输入。

环节	保持的一致性
预备知识库	模型辅助抽取；程序保留关系方向、来源及限定，建立关联索引
证据记忆	写回已观察到的原始事实；答案候选不能替代来源证据
协议交接	主体—关系—客体与限定一起传递；来源表去重，不裁已召回事实
隐状态接续	已编码登记与事实内容哈希一致时复用；新增或改变事实首次编码
记忆与查库	已驻留来源优先取回；来源缺口触发补查，不把高相似度当作答案正确性证明

这一机制处理两个具体工程问题：已经存下来的事实能否通过关联路径重新找到，以及关系方向、所属对象和限定能否完整到达下游。其贡献在于证据身份与计算复用之间的约束一致，仍需更多数据检验提取质量与检索泛化。

外部检索使用从当前计算状态校准得到的数值查询，避免上游再次生成检索文字；问题文本仍用于实体入口和会话指代绑定。小型查询映射使用预备知识样本校准，基础模型权重不变，不能称为整个系统完全免训练。

代码位置与验证

hypergraph_memory_method/prepared_knowledge.py:121
实体、关系参与角色与来源作用域建图；第158行写入图结构。

hypergraph_memory_method/source_context.py:174
来源独立成表，按来源及原文顺序交接完整关系与限定。

competition_agents/evidence_memory.py:109
存储原始证据；第37行执行关联记忆召回。

competition_agents/llm/latent_only_chat.py:237
事实标识与内容哈希登记，避免重复编码。

competition_agents/latent_hidden/calibrated_query.py:111
仅用预备知识样本校准数值查询映射，不读取评测答案。

tests/test_memory_source_alignment.py:13
验证来源写回、后续属性取回和已有关系不重复查库。

本轮隐状态首次编码252条事实，后续所有题目的各层统计都只计算新增位置；来源、问题与公共规则的回收计数均为零。跨题记忆复用与耗时的完整流程证据见第3页。经验记忆有独立存储与剪枝实现，但本轮没有实际采用，不列为第三项主要创新。

验证依据与贡献边界

完整流程使用真实 TopiOCQA 第153组原顺序10题、同一千问3.5九十亿参数模型及同一7篇来源知识库。显卡为 NVIDIA RTX 6000D。三组最终角色使用同一份回答要求，统一零温度、3072词元上限和32词元输出重复保护，分开记忆库并串行运行。模型加载、离线抽取建图和查询校准不计入任务时间。

完整十题指标	纯文本	协议字段	隐状态
总耗时（秒）	273.96	77.38	35.49
答案覆盖度	99.09%	88.75%	90.00%
中间交接文本	843.9 千字节	408.7 千字节	不生成中间文本；同进程驻留状态接续
后九题仅用记忆	8/9	9/9	9/9
平均记忆检索（毫秒）	6.33	8.04	1.55
最终输出词元	1916	864	952
角色模型调用	40	40	40

“答案覆盖度”沿用项目原评分，不等于验证全部额外叙述都正确。“仅用记忆”指本题有来源证据进入流程且没有查询知识库，属于使用记录。交接文本按实际正文计量；同进程缓存容量与网络传输是不同指标，本轮未测跨机器传输。

统一回答要求后的变化

三组最终角色使用完全相同的指令：依据原始证据回答当前问题、保留所需名称及日期、开放介绍给出概述、避免内部编号和重复说明。相同要求不保证模型输出同样长度；文本第六题仍产生较长回答，原始输出全部保留。

与上一版相比，隐状态最终输出从3380词元降到952词元，总时间从97.19秒降到35.49秒，缓存峰值从468.97降到374.12二进制兆字节。但答案覆盖度从98.75%降至90.00%，第5、6题为部分覆盖，且输出仍出现日期误述。因此本轮不能宣称在不影响准确率的前提下已经全面达到目标。

测试规模为一个模型、一个真实连续会话、每种方式单轮十题。代码执行有功能测试与独立入口，本文没有给出其完整十题性能成绩；也不把本轮结果外推到全部模型或全部数据集。

生命周期消融与复核依据

生命周期机制消融

固定完整来源十题	保留完整缓存	按生命周期回收
缓存峰值（二进制兆字节）	449.28	374.12
十题结束保留缓存	449.28	325.78
实际回收位置数	0	3034
原评分答案覆盖度	92.08%	90.00%
正常结束题数	10/10	10/10

该消融保持模型、问题、完整来源与最终提示一致，只改变回收策略；不包含在线检索，不能与完整流程耗时混合。峰值为缓存张量容量，包含裁剪时新旧层张量短暂共存，不包含模型权重或运行工作区，实测减少16.73%。回收组覆盖度降低2.08个百分点，因此目前证明的是容量下降及链路可运行，还没有证明回答能力完全保持。全部254项项目测试通过。

当前未完成原论文实现的同条件对照、多模型全量验证或统计显著性检验，不宣称普遍优于已有工作。来源事实与问题全部保留，但这不能替代对缓存回收语义影响的验证。

复核位置

完整结果：outputs/qwen35_ten_20261001/qwen35-ten-20261001-v80-v1/{plain,structured,latent}/result.json
机制消融：outputs/qwen35_ten_20261001/qwen35-lifecycle-20261001-v80-v1/
自动核查：完整结果目录内 final-audit.json；消融脚本 experiments/final_answer_lifecycle_ablation.py。
正文代码路径均相对 examples/competition_agents，行号以第8.0版为准。

已有工作

[1] Zou 等，Latent Collaboration in Multi-Agent Systems，2025，§3.1–3.2。
https://arxiv.org/abs/2511.20639

[2] Zhang 等，H□O: Heavy-Hitter Oracle for Efficient Generative Inference of Large Language Models，2023。
https://arxiv.org/abs/2306.14048

[3] Luo 等，HyperGraphRAG: Retrieval-Augmented Generation via Hypergraph-Structured Knowledge Representation，2025，§4。
https://arxiv.org/abs/2503.21322